

Développement de protéines *de novo*

Elyna BOUCHEREAU

2023-02-17

I. Introduction

Identifiant PDB	Score Forsa global	Score Norm Forsa global	Z-Score Forsa local	Longueur	Remarque
2XIW	93.550	1.396	5.532	66	Sans tag Histidine
1AZP	122.628	1.858	7.023	66	
1AZQ	122.606	1.858	7.022	66	
1BF4	88.762	1.409	5.461	63	
1BNZ	97.222	1.519	5.847	64	
1C8C	78.492	1.226	4.896	64	
1CA5	72.121	1.076	4.505	67	
1CA6	118.235	1.791	6.804	66	
1SAP	116.701	1.768	6.727	66	
1WD0	117.895	1.786	6.787	66	
1WD1	102.041	1.546	5.996	66	
1WT0	11.647	1.692	6.475	66	
1WTP	98.599	1.494	6.137	66	
1WTR	117.136	1.775	6.749	66	
1WTV	108.200	1.639	6.304	66	
1WTX	112.8979	1.710	6.537	66	
1WVL	121.016	1.513	6.333	80	
1XX8	64.767	0.967	4.138	67	
1XYI	124.251	1.883	7.104	66	
3LWH	134.211	2.237	8.004	60	
3LWI	125.677	2.095	7.553	60	
4CJ0	45.527	0.641	3.085	71	Sans tag Histidine
4CJ1	80.191	1.129	4.742	71	Sans tag Histidine
4CJ2	80.979	1.191	4.876	68	Sans tag Histidine

Score maximal est à 8.004 et score minimal à 3.085.

II. Forsa

1.1. Chargement des librairies et initialisation des variables

```
## # A tibble: 26 x 26
```

```
##           A      B      C      D      E      F      G      H      I      J      K
##      <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
##  1 0.0625      0      0 0.0938 0.109 0.0312 0.0781      0 0.0156      0 0.156
##  2 0.0625      0      0 0.0781 0.109 0.0312 0.0781      0 0.0156      0 0.203
##  3 0.0625      0      0 0.0781 0.109 0.0312 0.0781      0 0.0156      0 0.203
##  4 0.0333      0      0 0.05   0.117 0.0333 0.117      0 0.05      0 0.217
##  5 0.0333      0      0 0.05   0.117 0.0333 0.117      0 0.05      0 0.217
##  6 0.05        0      0 0.05   0.0833 0.0333 0.117      0 0.05      0 0.217
##  7 0.0625      0      0 0.0781 0.109 0.0312 0.0781      0 0.0156      0 0.203
##  8 0.0625      0      0 0.0781 0.109 0.0312 0.0781      0 0.0156      0 0.203
##  9 0.0625      0      0 0.0781 0.109 0.0312 0.0781      0 0.0156      0 0.203
## 10 0.0625      0      0 0.0781 0.109 0.0312 0.0781      0 0.0156      0 0.203
## # ... with 16 more rows, and 15 more variables: L <dbl>, M <dbl>, N <dbl>,
## #      O <dbl>, P <dbl>, Q <dbl>, R <dbl>, S <dbl>, T <dbl>, U <dbl>, V <dbl>,
## #      W <dbl>, X <dbl>, Y <dbl>, Z <dbl>
```

```
##### II. Initial round ----
```

```
nb_of_bests <- 10
```

```
nb_of_mutants <- 1000
```

```
nb_of_init_seq <- 10000
```

1.2. Création de la génération 0

```
### - 2.2. Generating the first batch of random sequences ----
```

```
sequences = {}
```

```
header = ""
```

```
sequences <- foreach(i=1:nb_of_init_seq,.combine = 'c') %dopar% {
  sequences[i]=paste(sample(amino_acid_pb_df$letter, seq_length, replace=TRUE, prob = amino_acid_pb_df$
  header = paste("Random_Sequence_",i,sep = "")
  sequence = paste(">",header,"\n",sequences[i],sep = "")
  write(sequence,file = paste("RD_SEQS/",header,".fasta",sep=""))
}
```

```
align_raw={}
```

```
align_seq={}
```

```
align_raw <- foreach(i=1:nb_of_init_seq,.combine = 'rbind',.inorder = FALSE) %dopar% {
  name_seq = paste("Random_Sequence_",i,".fasta",sep = "")
  align_seq = system(paste("./SCRIPTS/FORSA/forsa_global RD_SEQS/",name_seq ," OUT_DSSP_backup/2xiw_A.d
  ## We need to delete the file to avoid overfilling
  system(paste("rm ","RD_SEQS/",name_seq,sep=""),intern=T)
  align_seq[1] = paste("Random_Sequence_",i,sep="")
  align_raw[i] = t(align_seq)
}
```

```
align_raw[,4]=str_split_i(align_raw[,4],":",5)
```

```
align_df<-data.frame(query = align_raw[,2],
                    target = align_raw[,3],
                    z_score = as.double(align_raw[,4]))
```

```
row.names(align_df)<-align_raw[,1]
```

```
par(mfrow = c(1,1)) ## Réinitialisation de l'affichage
```


```
hist(as.numeric(unlist(align_df$z_score)),breaks = 100,
```

```
      xlim=c(-3, 11),
```

```
      main = "Valeur de Z-SCORE pour des séquences aléatoires\n selon une loi uniforme par rapport à 2xiw_A.d
```

```
ylab = "Nombre de séquences", xlab = "Z-Score",
col = rgb(0.83,0,1,0.7), border = F)
abline(v = c(3.085,8.004 ), col = "red",lwd=2)
```

Valeur de Z-SCORE pour des séquences aléatoires selon une loi uniforme par rapport à 2xiw



```
top_hit<-head(aligned_df[order(-aligned_df$z_score),,drop = F],nb_of_bests)
print(head(top_hit))
```

La génération a été faite et évaluée à l'aide de **Forsa** pour 10000 séquences aléatoires pondérées en fonction de l'apparition des résidues dans des séquences de protéines Sac7d. La répartition des scores suit une parabole asymétrique, similaire à une loi de poisson. Les scores restent en majorité en dessous du seuil du plus faible Z-score pour une séquence de référence.

1.3. Création des générations suivantes par mutation des meilleures

```
### III. Mutation cycles ----
par(mfrow = c(2,2))
for(cycles in 1:4){
  print(cycles)
  top_hit[,1]<-gsub('-', '', top_hit[,1])
  new_sequences = {}
  new_sequences_tmp = {}
  file_name_1 <- {}
  cpt = 1
  foreach(i=1:nb_of_bests,.combine = 'c') %dopar% {
    new_sequences_tmp=system(paste("./mutate_seq",nb_of_mutants,top_hit[i,1]),intern = T)
    #new_sequences_tmp = mutate_seq(top_hit[i,1],nb_of_mutants = nb_of_mutants)
```

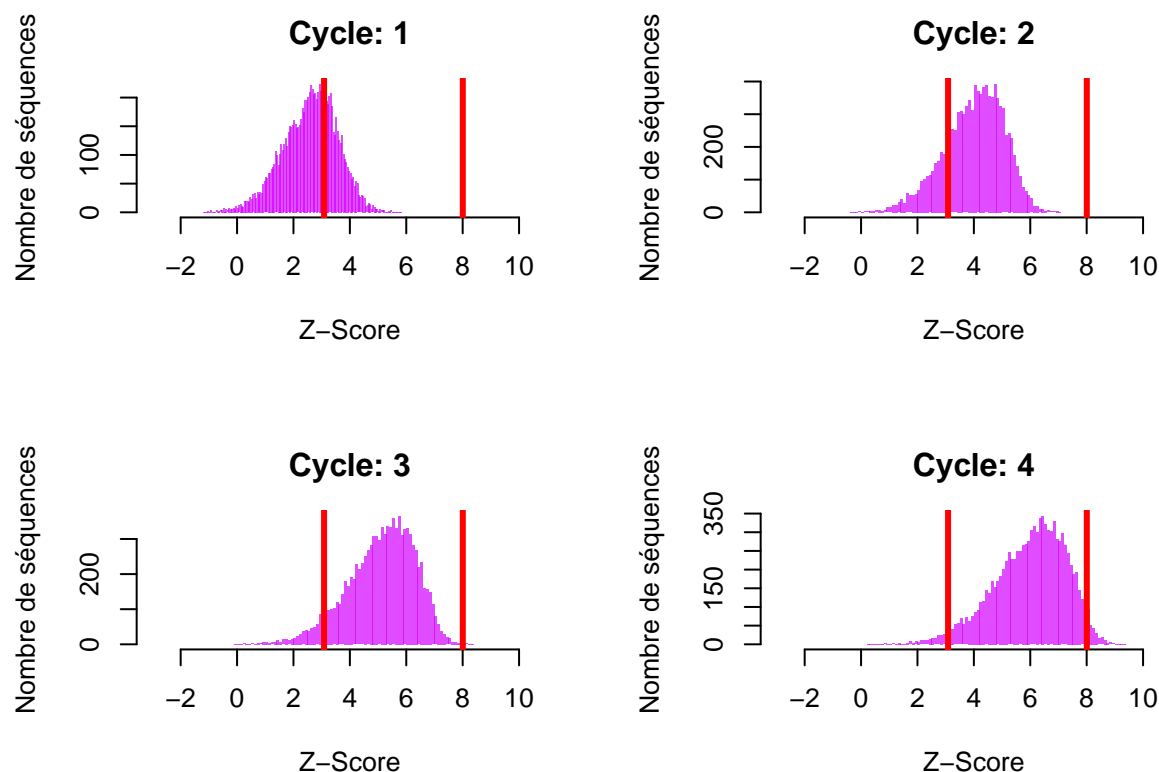
```

for (j in 1:(nb_of_mutants*2)){
  if(j %% 2 != 0){
    header <- new_sequences_tmp[j]
  } else {
    file_name = paste("Sequence_mutated_0.2_from",i,"_child_",j/2,sep="")
    sequence <- paste(header,"\n",new_sequences_tmp[j],sep="")
    #new_sequences[i] = sequence
    write(sequence,file = paste("MUT_SEQ/",file_name,".fasta",sep=""))
  }
}
}

align_raw_mut={}
align_seq_mut={}
file_names = list.files("MUT_SEQ/")
align_raw_mut <- foreach(i=1:(nb_of_mutants*nb_of_bests),.combine = 'rbind',.inorder = FALSE) %dopar%
  align_seq_mut = system(paste("./SCRIPTS/FORSA/forsa_global MUT_SEQ/",file_names[i] ," OUT_DSSP_back
  system(paste("rm ", "MUT_SEQ/",file_names[i],sep=""),intern=T)
  align_seq_mut[1] = paste("Random_Sequence_",i,sep="")
  align_raw_mut[i] = t(align_seq_mut)
}
align_raw_mut[,4]=str_split_i(align_raw_mut[,4],":",5)
align_df_mut<-data.frame(query = align_raw_mut[,2],
                        target = align_raw_mut[,3],
                        z_score = as.double(align_raw_mut[,4]))
row.names(align_df_mut)<-align_raw_mut[,1]

hist(as.numeric(unlist(align_df_mut$z_score)),breaks = 100,
     xlim=c(-3, 11),
     main = paste("\nCycle:",cycles),
     ylab = "Nombre de séquences", xlab = "Z-Score",
     col = rgb(0.83,0,1,0.7), border = F)
abline(v = c(3.085,8.004 ), col = "red", lwd = 3)
top_hit <- head(align_df_mut[order(-align_df_mut$z_score),,drop = F],nb_of_bests)
print(head(top_hit))
write.csv(head(align_df_mut[order(-align_df_mut$z_score),,drop = F],100),file = paste("Top_HITS_",cyc
}

```



```
#mtext("Valeur de Z-SCORE pour des séquences aléatoires\n selon une loi uniforme par rapport à 2xiw",
#      side = 3, line = -21, outer = T)
```

Dès le premier cycle, il est possible d'observer une nette amélioration des Z-scores, avec le pic de la répartition des scores sur le premier seuil. Au bout de 4 cycles, une grande partie des séquences permettent d'obtenir un Z-score supérieur à 8.


III. Conclusion et discussion

Lors de différents tests, il s'est avéré que de garder seulement le top 10 des meilleures z-score permettait d'avoir une convergence des résultats plus rapide vers des scores élevés. Le pool de séquences mutées passant à 10000 séquences au lieu des 100000 proposées. Cela permet également de diminuer grandement le temps de calcul malgré la parallélisation.

Avec un nombre de générations faible, il y a rapidement des séquences obtenant des z-scores élevé qui apparaissent. Des tests sur un nombre plus faible de séquences (1000) ont révélés des résultats similaires, mais avec une variabilité plus importante entre les essais. Les calculs ont été pu être réalisés dans un temps raisonnable (<5 min) sur un ordinateur portable grâce à la parrallelisation avec l'utilisation de 8 *threads*.

Ainsi avec 4 cycles de génération seulement, on obtient des z-score supérieurs à 9, pour un maximum à 9.735 avec la séquence "AQLPYEFYPGWPMMLVDPEGSEKIIPDGDESIPIFSMDGEKITHIVSEKGYVPEWWM-LADPFSE". Il serait possible ensuite de réaliser de la prédiction de structure par homologie, ayant une structure de référence. Cependant la protéine est très petite et regarder la différence entre les deux modèles sans tenir compte de la flexibilité de la protéine pourrais biaiser la comparaison. En utilisant le l'outil ROBETTA (<https://robetta.bakerlab.org/>), une modélisation par homologie à 2xiw a été réalisée et obtenant un modèle avec un RMSD de 0.000 avec la référence.

Pour conclure, cette approche utilisant les protéines blocs est efficace pour développer des protéines similaires à une référence mais avec propriété possiblement différentes.



3.2. Liste des séquences après n-cycles

query	z_score
AQLPYEFYPGWPMLVDPEGSEKIIPDGDESIPFISMDGEKITHIVSEKGYVPEWWMTL35	9.75
CTLSYEFYYGWPMMLVDPEGSKIIPDGDESIPISYDGEKIPHIVSEKGYSPDYWQTDAC	9.62
AQLMYFFPPGWPTVVDPEHSCKIIPDGDESIPISHDGEYIPHIVSEKGTSPWFMTG70	9.70
ASLMTETYPGQDMLYDPEGDYKILPPGDEPICISSMDGMKIQFIQSEKGYDPEKWH18A	9.68
AHVMYSLYPGYDMLVDPEGLCKYVPDGDEAIPISMDGEKIPYTQSEDGYPPEKW907	9.67
AQLPEEFYPGWPYLVDPEGSKIIPDGDESIPISLDGERIPHITCEKGYPPPEWHMTL37	9.67
AHAAYCFCPGWQYLVDPGRCKIFYDGDEEIFISCMEGEFIFTTQSEEGFSPEIWM916	9.69
AKLMYEFAPGWDMLLDPSGTCQIIPDGDESIPISMDGEKIPHTQSPKGYDPEKWM906	9.66
AKLMVETYPGQDMLNDPEGWYKIIVPGDEFIPISMDGEKIQFTVSEKGYDPEKDK37L	9.67
ADLPYEFYPGWPMLVDPEASCIHEDGDEYIPFISRDGEKIPHIVPEKGYNPEWWETL30	9.68
ASLMDETYPGQDMLMDPEGLYKIIPGDELIPISIMDGRKIIFPQSEKGYYPEKWK915	9.69
AHWIYFFYPGWDCVVDPPGLCKYVPDGDEPIISSMDGEKCPHWQSEKGFPEKWM18	9.68
AKAMYEFYPGWQMLVDPEGWYKIFYDGDEEIPISCMDEGEFIPTTQSEEGYNPEW913	9.68
AKLQYEFYPGKWQLVDPEGHEKIIPDGDERIISMMMDGEKIFHTFSEKGYGPSKVL916	9.67
CHEMYNFYPGRVMLHDPEGLCKAVPDGDEQIPISMDGEKIPWTQSEDGYPPEKEN917	9.67
AHLMYEFYQGWDMLLDPNGRCTIICDGDEVTPISLSDGTKIPHYLSEKGYPPEKWM917	9.67
AAIMYMFYEGWDMMLVDPERLCKIIPDGDNPIMISMDGEMIFRYVSEKGYVPEWW918	9.68
ASLMLHTYNGQDMLNDPEGCYKIIPGDFCIPISWMDGFPIQFTQSEKGEDPEKWK914	9.68
AMEMYNFYPGWDMMLVDPEGLCKYVPDGDEPIAISMDGEFIPHTQSPKGYPPRK913	9.68
AKIMYELYPGWDTLVDPERLCKIIPDGRNCIMISMDGEMIVGYVSEKGYPPEWW918	9.68
ASEMYNFYPGWMFLVSPEGLCWAVYDGDEEIPISLDGEKITHTHSEQGTPPEKWM913	9.68
AHEMYNFYPGWDPLVDPEGLCKYVPDGDEEIPISERDGSKVPHTMSEKGYPPEKWC78	9.67
AELMYEFAPGWDMLVHPSGKVKIIPDGDEYIPISMDGEKIPHTWSPKGICPEKWM917	9.67
AKGDDEFYPGKWQLVDPEGREKIIPDGDERIISMMMDGEKIPHTMSTKGYGPDKV913	9.66
ANEKYFFYPGWDMMLVDPEGRCWMIYLGDEEIHIMRPDGEKITNYYNENGYDPEDW31	9.67
ANRKYFFYPGWDMMLVDPEGRCWMIYLGDEEIHISFMDGYKITHLYNEKGIDPEKWM914	9.67
AQLPYEFYPGWPHLVDPEGSKIIPDGDSIPVSVDGEKIPHIVSEKGYVPEWCM913	9.68

AHEMYNFYPGWHMLVDPEGLCWVPDGDDEEILISSMDGEKIPHPQSEKGYPPPEKWM38LNDPFSE
 AQRPYEFYPGWPLLVDPEGSAKIIPDGDDESIPMSMDGEKIPHIVSAKGKVPEYWM91DIVPFSE
 AQRPYHIYPGWPYLVDHEGSCKIIPDGDDESIPVIKDGEKIPHIVSEKGYVPEWIMT9A29PFSE
 YSLMTFTYPPGGMMLTDPEGMYLIVPPGDDEEIPISSMDGEKIQFIQSEKGYDPEKDCD29ADSFMG
 AQLKYEYFYPGYPMMLVDPEGSQKIYPDGDDETIPICSDGLKINHIVSEHGYVPEWW91270FPFSE
 NKRQYEFMPGKWQLVDPEGREKIIIPDGDSDRIIISMDGEKIPFTDSEKGYGPQKVA91273VPFSE
 AHLMYFPCFGWDMYVDPEGRVKIIPDGDDEQTPIVLWDGEKIPHPLSEKGYCPEKLA91281YDIFSS
 ASLMTETKPGQDMLLDPEGDYKIIPPGDDEEIPISFDGEEIQFLQSEKGDPEKWKD91283CFCE
 ANLKYFFYPGWQMLVDPEGCSWMIYLGDEEYHIPTMDGEIVTHTYNEKGEPPEA91286LADRFYS
 AQLPYEFYPGWPMMLVDPEGSCKIIPDGDDESIPISSMDGEKIPHIVSEKGYVPEWW91284ADPFSE
 AQWPYEADPGCPYLVDPEGSNNIMDGGESIPHIQMDGEKIPHIVSEKGYVPEDLM91289DIFSE
 AKIMYEFVPGFDMMLVDPERLQCIIPDGDNCIMISSMNGESIMRYQSNKGYNPEWW91287LEPFSE
 AQLPYESYPGWPLLVDPEGSCKIIPDGDDESIPISSMDGEKIPHIVSEMGYVPEWWMT91283HECF
 AKIMMEFVPGWDGLVCPEGLCLFIPDGDNCIMIMSMNGEMIYRYQSWKGYPPEKWM91282LRDPTSE
 ADTPYEFYPGWPMMLVDPEGSCKIIPDGDDESIPWCSGDGEKIPHIVCELDYDPEWW91289ACHFSE
 AQLWYEFYPGWPMMLVDPEGSCKAEWDGDEKIPISSMDGEKIPCILSEKGSPPPEWW91288ADHFSE
 AQFPYEFSPGHIMHVGPAGACKIIPDGDDESIPISSMDGEKICHIVSEKGYPPPEWWYT91281PFSP
 AKLMYNFAPGWDMLVDPSGQCKIIPDGDDEEILISSMDGEKIPHTASPKGYHPEKWM91288ADPFSE
 AKWQYESWDGKWQLVDPEGREKIIIPDGDDEVIPISMMDGEKIPWTASEKGYGPMK91287LAVPHSE
 AKLQYEFYPGKWQLVDPEGREKIIPDGDGKRIIISMDGLKIPHTKSEKGYHPQKV91285AVPFWF
 AGEPYNFYPGWDMMLIDPEGLCKYVPDGDDEYIPSSMDGEKIPRTQSESGYPPEKWM91283LHAPFSE
 AKLMTETYPGQFMLNDPEGDPKIIQPGDDEEIPISSMDGEKIKFTWSEKGYDPEKWB91287ADHFWE
 AKMMREQYRGWDMMLVDPEALCKVIPDGRWCIMIMSMDGECIPFYYSIKGYDPEW91287BLRDIFSR
 AHLMYEFYFGWDMMLVDPEGRCKIIPDGDDEEKEISLPDGEKIPHYMSEKGYSPEDW91287VDPFSA
 VKLQYQTYPGKWQLVDPEGRTKIIPDGDDEEIIICMCDGEQIPFTDSETGYGPQKVA91287LAVPFSE
 AKAIWEFYPGWQMLVDPEGRCKIFYDGDDEVIPITCQDGEFIPTEQSEYGYTPDKW91285ADPFSG
 AHLMYEFYFGWDLVDPRGRTKIIPDGDSDWTPIILRDGEKIPHYGSEHGYCPEKWB91283CDPFSE
 AHEMYNFYPGWDMMLVDPEGLQKYVPDGDDEEHPWFSMDGQKIPHQQSEKGYPPPEKWM91282DLADFFYE
 ANLKYCRYTGWDMMLVDPEGRCWMIYNGDEQIHIIQMDGEKITHITYNKKGFDEK91286WDLADPFPE
 MKIMEWFYPGWIMMLVDPERLCKIIPDGDNPIMSMMDGEMIPRYQSEKGVVPEWW91288FMPSQE
 AQLPYEFLPGWPMNVDPENCKIIPDGDDESELISSMKGSKIPHIVSPKGYDPKWIM91282ADPFQE
 WNLLYFFYPGWDMMLVDPEGRCMMIYDGREEIHIMQMDGEKITHIYNEKGYDPEKWA91280LADPFYE
 AQWPYEAAYPGWPMMLVDPEGSCKTIPDGDDESIPWSSMDGEKIPHWVSEDGYVPEWW91289LADPFSE
 AKIMYKFYPGWDMMLVDPEQLTVIFLDGDNIMIMSMMDGQMIPRYTSEKGYVPESW91289TDPFSE
 ASFMTETYPGQDMLADPEGDYKEIIPDGLIPSSMNGEWIIFTQSEKGYDPEKWB91288ADVMSE
 AQLPYERYPGWPMMLVDPEGSCKVVPDGDDESIPISSMDGEKIPHIMSEKGYVPEWW91283ADPFST
 AKLQYEFYPGKWQFVDPDGREKIVPDGFERIIFMMDGEKIPHTPCEEGYHPQRTA91283DAVHGSE
 AHEMLHKQPGWAMLDPDEGLCKYVKDGDDEEIVISSYDGESIPHTQSEKGYPPPEQW91282ADNFSG
 AKLQYFPFYPGKWTVVDPKDRKIIIPDGDDEEIIISMDGEKIPHSDSPKGYGPQKVA91289VPFSE
 AQLPYEFYPGWPYLVDPEGSCKIIPDGDWSAVVSSMDGEKPPHIVSEKGYVPEWWMT91282ADPFSG
 IHEMYNFYPGWDMMLVCPEGLCKYVPDGDDEEIMISIMDGEWIPATQSEAGYPPEKWM91282ADPFSG
 AHLYYEFYFGWDLVDPEGRCKIVPDGDNETPIWLWDGQPIPHYLSEKGNCPK91280BLVDPFSE
 AKLNWEFYPGKWQLVDPEGREKSIPWGDDEEIIIVMMDGETIPITDDEKGYGPQKV91285LAVPFSE
 AHLMYEFYFGWVMLVDPWGRKKIIPDGDDEEWPISEWDGEPIPVYLCEKGQCPEKWM91284DLVQPFSD
 ARLPYEFYPGLPVLVDPEGRCKIIPDGDISIPISSMDGEWIPHIVSEKGYAPEWWMT91289VPFSE
 AKLMYEMAPGWDMLVDPGKCKIIPDGDDEKICIVSMMDGEKIPHTQSPKCYHPEKWM91285ADCFSG
 LKIMYEFTPGWDMVVDPERLGAIPDGDNCIMIMSMMDGEMIPRYQSEKGYCPEWW91282LSPLSE
 AKIFYIFYPGWRLVDPERLCKIIPDGENIIMIMSMMDGEMIPRYNAKGYYPENWM91288RHPFSW
 AHENDNFYPGEIGLVDPEGLCKYVPDGDDECIPISSSDGEKIPHTQSEKGYPPPEKWM91287DPPFQE
 AVLMYEFYPGWDMMLKDPEGRQKIIPDGDDEIPICSPKGEKIPHTQSEKGYPPEHW91288AGMNSA
 AGLQYEHHPGKWQLVNPEGREKIIIPDGDDEEIIISMDGEKVPHTPSEKGYGPQKV91287LAVHFSE
 AEIMFYFYPGWDMMLVDPERLCYIIPDGDNCIMIMSMDGECIPFFQSEKGYVPEWW91287RKPFNE

query	z_score
AALPPAEYPGQPMMLVDAEGSDKIIEGDESIPISSMDGEDIIHIVSEKGYVPEWWMT	9.147
AHLMTETYPGQDMLNDPEGDYIIPPGDFEIPISSIDGEKIQFTQSEKGLDPEKWK	9.106
WELQYEFYPGKWQLVDPEGREHHIWDGDERIIISMMDGEKIPHTMSEKGYKPQKQ	9.065
AKLQYEFYPGKWQLLDPEGREKAIPDGDEWIIISYMDGEVIPHTKSEKGYGPQKV	9.058
AHECYNFYPGWDMMLVDPEGLCKPVPSGDEFIPESIMNGEKIPHTQSEKGYPPEKW	9.056
AQLPYEFMPGWPMMLVDPEGSCKIIPDGDGSIPISSMDGEKIPRIVSEKGYVPEWRM	9.054
RKAMYEFYPGWQMLVDPEGRRKIFNDGDEPIPISCMDGEFIPTTQSEEGYVPEKW	9.053
APLPYEFQPGWCYLVDPSGKEKPIPDGEERCPINSMDGNKIPHTQSPKGYNPEKLM	9.045
AQLFYEFYPGWPMMLVDPAGSQKIIPDGDHSIPISSMDGEKIPVIVSEKGYVSEWWM	9.044
AKAIYEFYPGWQMCVDPEGRCIKFMQGDDEIKISCMDGEFIMTTFSEEGYVPEKW	9.044
AHLMYEFAPGWDVGVDPSGRCWIIPDGDARVPISSMDGAHICWTQSPKGYNPEKW	9.042
AQCPYEFYPGTPMLVDPESSCRIIDDGDESIPISSYDGEVPHIVSEKGYQPEWWM	9.037
AKLQHHFYPGKWGLVAPEGRKKIIPDGDDERQIISMMDGEKIFHATSEKGYDPQKV	9.033
FNLKYFFFKGWMMLVDPEGRCWMIYLGDEMHIRSQMDGAKITCTYNEKGYDPEK	9.033
AKLQYEFYPGKWHLVDPEGREKIIPDGDDERIIISMMDGEKIPMTDSEKGYGPQK	9.028
ACLKTETYPGQDMLNDPEGQYKIVPPGDQEIPISSMDGEKIQFTQSEKGYDPEKW	9.028
AQLTYEFYPGWPKLVDPEGRMKIIPDGDDESIPYSSMDGEKIPHIVSEKGMVPEWW	9.021
QDQTHEFKPGKWQCFDPELREKIIPDGEERIIPMMMDGEKPIHVMSEKDYCPQKV	9.021
ANGMYNFYPGWDMMLVDPEGLTKYVPDGDDEIPYSSMDGEKIAHTVSEKGSTPEK	9.021
AHEMQNFYPGWDMMLVDPEGLCMYVPDGDDEIQPISSMNGEKIRHDMSEKGFPEK	9.021
AHEMYNFYPGWDMMLVDPEGLCKRVPDGDDEMIPISSMDGEKIPHTQTEKGYPPEK	9.021